ИНЖЕНЕРИЯ ДАННЫХ

Анализ IT-вакансий: Go-разработчик

Домашнее задание 3 · вариант 7

Выполнила

Вита-Виктория Гиалтсо-Мижа

Группа j3313

ИСУ 466703

Анализ IT-вакансий: Go-разработчик

Инженерия данных, домашнее задание 3. Индивидуальный вариант 7: «Программист, разработчик на Go». Фактический запуск 27.10.2026.

Источник и границы данных

Исходный архив hh.zip из учебного чата содержит 10 000 JSON-файлов вакансий. SHA-256: c45f6ad4ad3c6ec65f3a823e33bd04da1c7f2d264a1f22d14b4206730a3381b3. В каждом объекте есть название, регион, список ключевых навыков и необязательная зарплата. Скрипт prepare.py преобразовал данные в JSONL без изменения смысла полей.

Вариант отбирается по отдельному слову Go или Golang в названии вакансии. Это явное условие записано отдельно в Python-мэппере и в SQL DuckDB. Отобрано 124 вакансии, у 101 есть навыки, лишь у 13 указана зарплата в рублях.

Хранилище и доказательство загрузки

Объект RustFS	Размер	PUT	HEAD	ETag совпал
s3://hh-lake/raw/vacancies.jsonl	3 067 413 байт	200	200	да

Результаты собственной MapReduce записаны обратно в hh-lake/results/go/skills_1.json, skills_2.json и skills_3.json; для каждого выполнен HEAD 200 после PUT 200. Код и полный машинный вывод находятся в results/evidence.json.

Методы и сверка

MapReduce читает S3-поток чанками по 1 МиБ, собирает полные строки JSONL на границах чанков и передает их двум процессам-мэпперам. Мэппер нормализует навыки (trim, lower, удаление дубликатов), строит сочетания C(k,1), C(k,2), C(k,3); reducer суммирует Counter. DuckDB через httpfs читает тот же S3-объект, самостоятельно фильтрует названия и считает сочетания тремя SQL-запросами с UNNEST. Сравнены полные словари ключ→частота; расхождений нет.

Размер	Уникальных	Всего вхождений	Частейший набор	Частота	SQL=MR
1	115	601	golang	81	да
2	1 008	2 382	golang + postgresql	38	да
3	4 522	9 106	docker + golang + postgresql	17	да

Число вхождений растёт 601 → 2 382 → 9 106, поскольку одна вакансия с k различными навыками даёт k одиночных навыков, k(k−1)/2 пар и k(k−1)(k−2)/6 троек. Это не рост числа вакансий.

Время и память

Три последовательных запуска каждого алгоритма на одном входном объекте. Время - wall-clock для подсчёта; peak RSS - пиковая суммарная память процесса и его дочерних процессов, опрос каждые 5 мс. Прогрев кеша и рост памяти процесса DuckDB между попытками влияют на цифры; выводы о скорости относятся к этой машине и этому малому набору.

Метод	Запуск	Время, с	Пик RSS, МБ
Свой MapReduce	1	0.4532	183.29
Свой MapReduce	2	0.1448	186.68
Свой MapReduce	3	0.1451	189.63
DuckDB SQL	1	0.0658	131.42
DuckDB SQL	2	0.0654	152.85
DuckDB SQL	3	0.0656	163.53

Медианное время: MapReduce 0.1451 с, DuckDB 0.0656 с (DuckDB быстрее примерно в 2.2 раза). Пользовательская реализация создаёт два Python-процесса, что объясняет больший суммарный RSS на этом объёме.

Три региона

Выбраны три региона с наибольшим числом Go-вакансий: Москва, Санкт-Петербург и Нижний Новгород. Регион вакансии взят из area.name. Медианы ниже используют только опубликованные RUR-зарплаты.

Регион	Вакансий	С зарплатой	Медиана, руб.
Москва	67	6	300 000
Санкт-Петербург	29	2	337 500
Нижний Новгород	7	1	200 000

Регион	Топ-3 навыка	Топ-пара	Топ-тройка
Москва	golang (44), postgresql (26), go (22)	golang + postgresql (21)	docker + golang + postgresql (10)
Санкт-Петербург	golang (20), go (14), postgresql (13)	golang + postgresql (11)	golang + postgresql + sql (6)
Нижний Новгород	linux (4), go (3), golang (2)	go + linux (3)	c + go + linux (1)

В Москве 67 вакансий против 29 в Санкт-Петербурге и 7 в Нижнем Новгороде. Golang и PostgreSQL часто встречаются в обеих столицах. У двух последних регионов зарплатных записей только 2 и 1, поэтому сравнение их медиан нельзя считать устойчивым.

Навыки и опубликованная зарплата

Берём только RUR-вакансии с хотя бы одной указанной границей зарплаты; используем середину диапазона либо единственную границу. Для сочетания сравниваем его медиану с медианой самого частого одиночного навыка из него (частота считается внутри зарплатной подвыборки). Разница описывает ассоциацию, а не причинное влияние навыка. В таблицах показаны группы минимум с двумя вакансиями; сам исходный набор - лишь 13 зарплатных записей.

Связаны с более высокой медианой: пары

Сочетание	n	База	База, руб.	Группа, руб.	Разн., руб.
go + rabbitmq	3	rabbitmq	239 750	450 000	+210 250
golang + kubernetes	2	golang	225 000	325 000	+100 000
golang + redis	2	golang	225 000	325 000	+100 000

Связаны с более низкой медианой: пары

Сочетание	n	База	База, руб.	Группа, руб.	Разн., руб.
git + rabbitmq	2	git	225 000	172 375	-52 625
go + kafka	2	go	312 500	277 500	-35 000
rabbitmq + sql	2	rabbitmq	239 750	219 875	-19 875

Связаны с более высокой медианой: тройки

Сочетание	n	База	База, руб.	Группа, руб.	Разн., руб.
go + golang + rabbitmq	3	golang	225 000	450 000	+225 000
golang + kubernetes + postgresql	2	golang	225 000	325 000	+100 000
golang + kubernetes + rabbitmq	2	golang	225 000	325 000	+100 000

Связаны с более низкой медианой: тройки

Сочетание	n	База	База, руб.	Группа, руб.	Разн., руб.
git + golang + rabbitmq	2	golang	225 000	172 375	-52 625
postgresql + rabbitmq + sql	2	postgresql	239 750	219 875	-19 875
docker + git + postgresql	3	postgresql	239 750	225 000	-14 750

Ограничения

Сочетания Go и Golang сохранены как разные исходные теги: такая пара часто означает два написания одного языка, а не две компетенции. В исходном архиве часть зарплат указана gross, часть net; конверсия не проводилась. Единичные опубликованные зарплаты вне Москвы особенно ненадёжны. Наблюдаемые отклонения медиан нельзя трактовать как эффект обучения навыку или переносить на весь рынок труда.

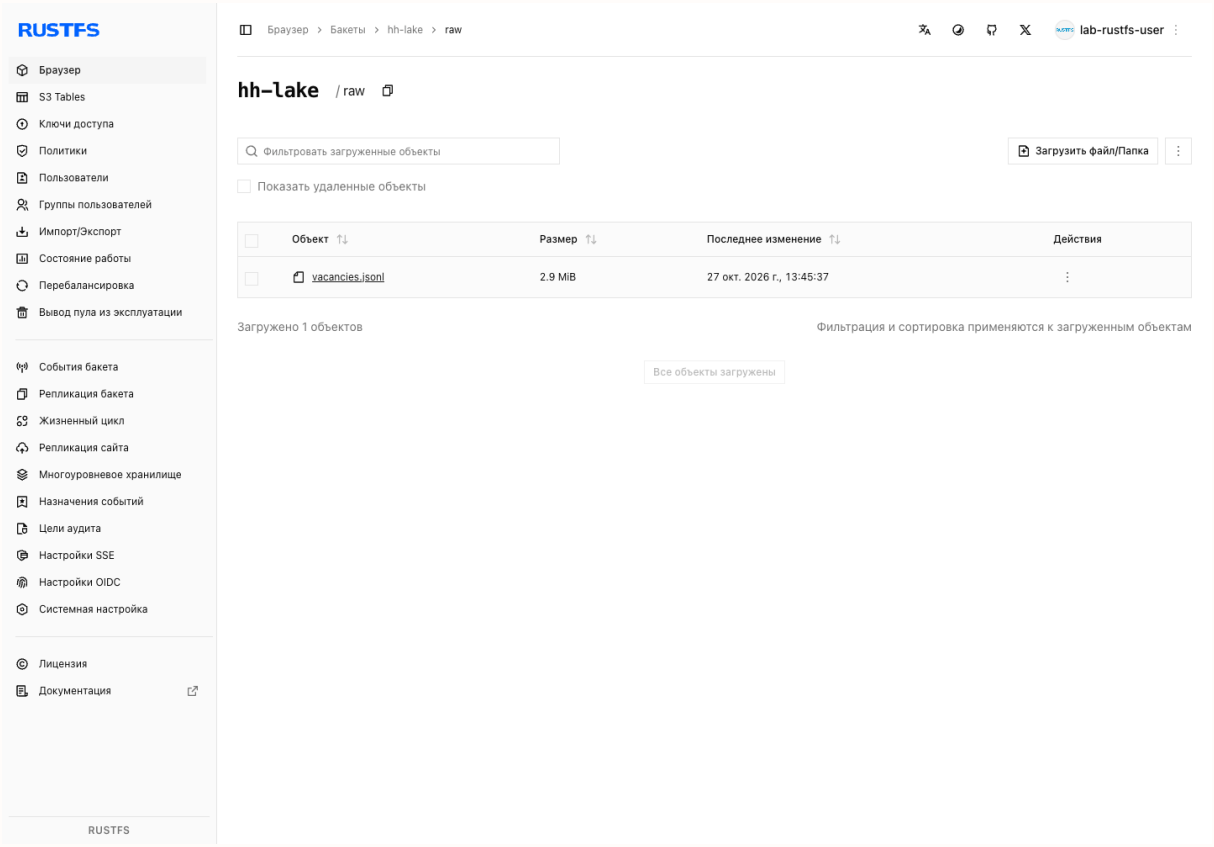
Повторяемость

Команды запуска и конфигурация - в README.md; исходный архив проверяется SHA-256. Подробные JSON-результаты, полный протокол трёх профилей и контрольные числа - в results/evidence.json. Объекты результатов загружены в бакет hh-lake, HEAD-проверки всех четырёх объектов получили HTTP 200.

Подтверждение в RustFS

Снимки сделаны в локальной консоли после загрузки исходного JSONL и трёх результатов MapReduce в бакет hh-lake.

Исходные данные в raw/



Сохранённые результаты MapReduce

Три объекта навыков, пар и троек в results/go/.

